

— ЗАЩИТА ПРОЕКТА · LLM-ИНЖЕНЕРИЯ

OSS COPILLOT

AI-агент, который ревьюит pull request'ы на GitHub и помогает найти open-source проект, в который стоит начать контрибьютить — один граф LangGraph, два режима, человек всегда подтверждает финальное действие.

→ `oss-copilot-dmitriy-solo.vercel.app`

ПРОБЛЕМА

Один пользователь, две реальные боли

PR Reviewer

Разработчик хочет получить качественное автоматическое ревью своего PR **до** того, как звать живого ревьюера — сейчас это либо ждать часы/дни, либо выкладывать код без второй пары глаз.

Repo Matcher

Разработчик хочет начать контрибьютить в open source, но тонет в поиске "с чего начать" — звёзды на GitHub ничего не говорят о том, дружелюбен ли проект к новичкам прямо сейчас.

РЕШЕНИЕ

Один агент, один граф, свободный текст на входе

Пользователь просто описывает, что нужно — "review this PR <ссылка>" или "I know Python, want to contribute to a CLI tool". Классификация запроса — это и есть первое реальное ветвление графа.

review

Ревью файл за файлом — баги, security, тесты, breaking changes — с граундингом в конвенциях конкретного репозитория.

repo_match


Ранжированный список кандидатов по fit-score (CONTRIBUTING, good-first-issues, активность), не по звёздам.

human-in-the-loop

Ни один комментарий не публикуется в GitHub без явного подтверждения человека.

— АРХИТЕКТУРА


От браузера до GitHub и обратно



Ни один узел графа не ходит в GitHub или OpenAI напрямую — только через MCP tool layer или `langchain_openai.ChatOpenAI`, поэтому каждый LLM-вызов автоматически попадает в LangSmith.

— LANGGRAPH

Ветвления, циклы, human-in-the-loop



Оба цикла ограничены (файлы ≤ 10 , кандидаты ≤ 5) — не могут убежать. Обе паузы — один и тот же механизм: `langgraph.types.interrupt()` + `Command(resume=...)`.

— СОБСТВЕННЫЙ MCP-СЕРВЕР


6 инструментов поверх GitHub API

<code>get_pr_diff</code>	diff и метаданные pull request'a
<code>get_pr_files</code>	patch по каждому файлу — для поочерёдного ревью
<code>post_pr_comment</code>	write — вызывается только после подтверждения человеком
<code>search_github_repos</code>	поиск репозиториев-кандидатов
<code>get_repo_health</code>	CONTRIBUTING.md, good-first-issues, активность, лицензия
<code>get_good_first_issues</code>	открытые issue для выбранного репозитория

Граф вызывает их через настоящий MCP-протокол (`mcp.Client`, `in-process`) — не прямым импортом функций.

— RAG-ПАЙПЛАЙН

Ревью, заземлённое в конвенциях конкретного репозитория



Retrieval подмешивается в промпт review-узла перед анализом каждого файла; если для репозитория ничего не проиндексировано — граф не падает, просто ревьюит без граундинга.

— МУЛЬТИМОДАЛЬНОСТЬ

Vision-анализ скриншотов в описании PR

Скриншот или demo-гифка в описании PR — это то, что текстовый diff физически не может увидеть: несовпадение с заявленным изменением, сломанный layout, баг, видимый только на картинке.

реальный пример `facebook/docusaurus#7036` — demo-гифка в Test Plan была найдена, проанализирована vision-моделью, и вывод попал в финальный ревью-комментарий вместе с текстовыми замечаниями.

— МОНИТОРИНГ

LangSmith: трейс каждого LLM-вызова

<code>chat + vision</code>	трейсятся автоматически через <code>langchain_openai.ChatOpenAI</code> — без дополнительного кода
<code>embeddings</code>	найденная слепая зона — <code>OpenAIEmbeddings</code> не <code>Runnable</code> , LangSmith её не видит; закрыто явным <code>@traceable</code>
<code>thread_id</code>	связывает оба <code>ainvoke()</code> одного HITL-сценария (до и после <code>interrupt</code>) в одну историю в дашборде

— GOLDEN DATASET · 30 ПРИМЕРОВ

Две метрики — не одна


6 bug · 6 security · 5 missing_tests · 5 breaking_change · 8 clean — синтетические, ради точной разметки (два диффа, похожих на 95%, могут отличаться именно строкой с багом).

0.80 ACCURACY	0.79 PRECISION	1.00 RECALL	0.88 F1	3.73/5 LLM-AS-JUDGE
-------------------------	--------------------------	-----------------------	-------------------	-------------------------------

Accuracy = сказал ли что-то, когда должен был. Judge = совпадает ли суть комментария с реальной проблемой. Они расходятся — missing_tests: accuracy 1.00, judge всего 2.60 — модель замечает "что-то не так", но часто не то.

— A/B ЭКСПЕРИМЕНТ


gpt-4o-mini против gpt-4o



Решение: остались на gpt-4o-mini. Recall выше (1.00 vs 0.95 — gpt-4o пропустил реальный баг), judge score не ниже, а стоимость — в 23 раза меньше.

— ГИПЕРПАРАМЕТРЫ

Temperature подобрана
экспериментом,
не угадана



При $t=0.7$ разброс числа комментариев между повторами одного и того же файла ненулевой; при $t=0.0/0.2$ — нулевой. Judge-score одинаков у 0.0 и 0.2 → **переключили дефолт на 0.0** — то же качество, детерминированность бесплатно.

— GUARDRAILS · КЭШ · FALLBACK

Три слоя надёжности поверх базового графа

Guardrails

Diff — untrusted input. Детектор prompt-injection предупреждает человека в HITL-запросе; секреты вырезаются из комментария до публикации.

Кэш

Точный, не семантический — похожие диффы могут отличаться той самой строкой с багом. Повтор PR: 7 вызовов OpenAI → 1.

Fallback

gpt-4o-mini → gpt-4o при таймауте. Проверено реальным 0.001с таймаутом против живого API — переключение сработало.

— CI/CD · DOCKER · ДЕПЛОЙ

Живой публичный стек



GitHub Actions гоняет golden dataset evals на каждый push — реально зелёный в облаке, не только локально.

6 реальных багов найдено и починено при деплое — не гипотетических: контейнер слушал не тот порт (\$PORT), backend работал на старом образе, Qdrant-сервис ни разу не был задеплоен, Vercel закрывал сайт SSO-стеной. Каждый пойман живой проверкой, не чтением кода.

— ИТОГИ

Что сделано и что дальше

Все обязательные модули T3 реализованы и проверены вживую: LangGraph + MCP + Skill, RAG + мультимодальность, LangSmith + evals + A/B, обоснованный выбор модели и гиперпараметров — плюс guardrails, кэш, fallback, CI/CD, Docker, публичный деплой.

Главная находка: гипотеза "модель сильнее — значит лучше" не подтвердилась данными — gpt-4o-mini выиграл у gpt-4o по recall и judge-score при 23-кратной разнице в цене.

→ oss-copilot-dmitriy-solo.vercel.app

Дальше

auth	аутентификация пользователей
voice	голосовой интерфейс
users	реальные пользователи и обратная связь